TRACER: Do Language Models Actually Use Compiler Feedback?
A Causal Study of Feedback-Guided Formal Proof Repair
编译反馈的因果与语义价值：开题报告

王润祺（Runqi Wang）　陈钊炀（Zhaoyang Chen）
NLP and Symbolic Reasoning　2026 年 11 月 2 日
https://github.com/runqiwang777/TRACER

Abstract

本研究依据 2026 年 11 月 2 日修订计划 R1，研究编译反馈的因果与语义价值：反馈是否超出再次生成的收益，诊断语义如何影响行为，何种表示更具成本效益，以及反馈在何类错误上如何起作用。前期 repair24 的 864 个任务实例尚未显示稳定的反馈正增益，作为研究动机。主研究在五项目、254 道真实历史修复题上固定首轮失败候选，采用三供应商模型的嵌套设计。当前 v3 保持冻结协议；后续先复核诊断表示和错误状态，再独立设计字段级定向语义干预，最后在独立材料上检验确定性反馈选择。Error-State Graph 与 Adaptive Router 支撑研究后半段，而非预设收益。本稿沿用计划对应的已保存快照，尚不报告完整 v3 效果。研究拟交付真实修复基准、诊断信息结构与语义响应证据，以及可独立验证的错误状态分析。

1　研究问题与动机

形式化证明为语言模型提供了精确的外部检查器：在声明、依赖与可信边界固定后，Lean 能检验候选证明是否成立。但检查器提供了错误，并不意味着模型正确利用了错误。重试次数、历史候选、诊断文本、检索示例和输出预算可能共同影响成功率。

原计划书的四个 RQ 保持原义。**RQ1：反馈是否真正有效？**真实反馈能否在相同失败起点上优于无内容重试？**RQ2：反馈语义是否重要？**真实、同类无关与反事实反馈是否引起不同结果，模型是否跟随错误诊断采取对应修改？**RQ3：何种表示有用？**raw、normalized、structured 在成功、长度、token、延迟和编译调用上的权衡如何？**RQ4：何时、如何起作用？**效应是否依赖错误类别，原有信号是否被解决，又引入了什么错误？

总体逻辑为 **Measure–Understand–Exploit**：先估计反馈内容的作用，再分析语义敏感性与错误状态，最后检验是否能据此选择更合适的反馈。三供应商覆盖服务于这些 RQ；不同模型是独立验证条件，不能取代对语义和行为的研究。

2　相关工作与研究定位

LeanDojo 将程序化 Lean 交互、数据提取与检索增强证明纳入可复现环境 (Yang et al., 2023)。Baldur 研究整体证明生成和训练后的修复模型 (First et al., 2023)；DeepSeek-Prover-V1.5 使用证明助手反馈进行强化学习和搜索 (Xin et al., 2024)。APOLLO 将 Lean 分析、失败子证明定位和 LLM 修复结合 (Ospanov et al., 2025)。这些工作说明编译器引导修复与检索均有充分先例。

Li and Li (2026) 是 TRACER 反馈对照设计的重要参考：其在 MiniF2F 上固定失败证明，比较诊断与重试条件，使用 Qwen3.6-27B 与 DeepSeek-Prover-V2-7B。TRACER 当前的研究对象是三个一方 API 模型与真实项目历史修复，并独立检验可追溯诊断表示和错误状态差异。不同模型提供外部有效性检验的价值，尚不等于已经取得方法或性能优势。

因此，拟形成的增量围绕**真实修复基准、诊断信息结构与语义响应，以及独立验证的错误状态反馈选择**组织 (TRACER Contributors, 2026)。跨供应商模型和可复查轨迹支撑这些贡献。固定失败候选、匹配错诊断或反馈循环本身不单独作为首次提出的贡献。

3　前期结果：修复增加，但归因不足

3.1　已完成的六臂研究

前期冻结 repair24 的 24 道人工构造题，采用两个 DeepSeek 家族配置、三次重复和六个研究臂，共 864 个任务实例。每任务最多三轮。独立题目只有 24 道，实验臂和重复不扩充题目样本量。

汇总结果由 735/864（85.1%）首轮成功增加至 811/864（93.9%）三轮内成功，增加 76 个实例，即 8.8 个百分点。它说明有界循环可恢复部分失败，不能单独估计诊断的因果效果。

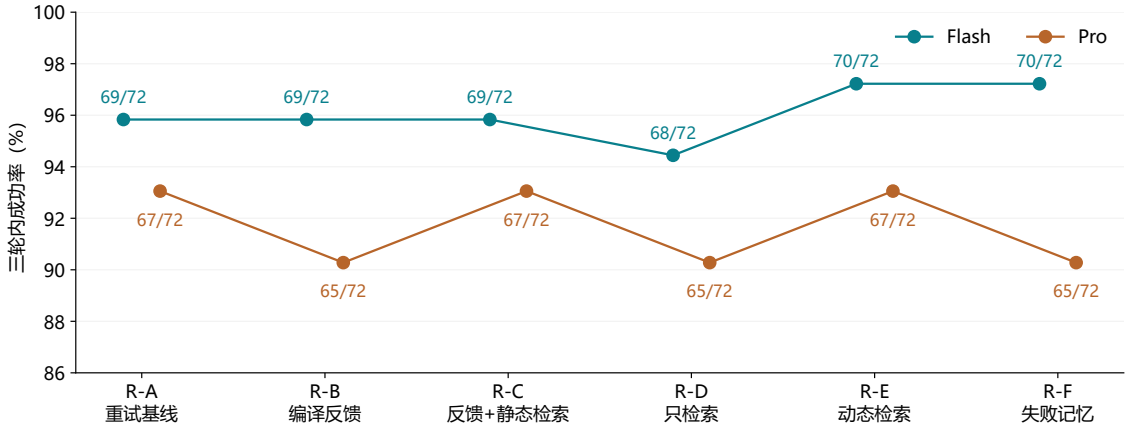


Figure 1: 前期六臂三轮内成功数。每点分母为 72 个任务实例。R-A 为重试基线，R-B 为反馈，R-C 为反馈与静态检索，R-D 为只检索，R-E 为动态检索，R-F 再加入失败记忆。纵轴为局部范围。

图 1中，主比较 R-B−R-A 在 Flash 为 $69/72-69/72=0$，在 Pro 为 $65/72-67/72=-2/72$。动态检索和失败记忆也未在两配置中稳定胜出。不能从这一批次得出“反馈必然提升”或跨供应商泛化结论。

3.2 证据与限制

完整前期工件目前保留在本地归档，不随当前精简 GitHub 仓库发布。本次直接读取原始汇总，核对 864 任务、811 个 AI 辅助复核成功证明以及 5,116,954 tokens；既有发布审计登记了 811 份证明的独立复编译。本次文稿更新未重新复编译这些证明。AI 辅助复核与纯人工审查分别标注。

这一结果推动研究从“多轮是否增加成功”转向“诊断内容在相同失败起点上带来什么变化”。v3 因此采用同候选分叉，并扩展真实项目和模型来源。

4 TRACER-REAL v2：真实历史修复

4.1 冻结与纳入

六个候选上游的历史扫描与纳入过程已冻结，共筛查 1,576 个候选，256 个通过历史修复对门禁。SciLean 的 2 题未达到项目纳入门槛，最终 test 划分包含五个项目、254 题；加上 development 和 validation 数据，manifest 共 265 题、8 个项目。

每题固定目标声明、修复环境和证明区域，要求旧证明在该环境失败、参考修复证明通过。参考证明与 provider 运行路径隔离。按上游项目划分开发、验证、测试，避免在同一项目上调试后再报告该项目的测试泛化。

PhysLean 占 $94/254=37.0\%$。原 35% 单项目占比门禁在 provider 调用前公开修订为 40%；该修订与原阈值均须披露。项目等权主分析降低大项目支配程度，但不能消除题目分布与项目筛选偏差。

测试项目	历史修复题
Equational Theories	53
FLT	47
LeanAPAP	16
PFR	44
PhysLean	94
合计	254

Table 1: TRACER-REAL v2 冻结测试划分。

4.2 任务的解释边界

这些任务源于真实提交历史，并不自动覆盖所有维护故障，也不排除训练数据污染。源代码许可、上游版本、环境和排除原因应随发布包交付。声明直接重合审计能够识别部分泄漏，不能证明不存在语义等价或预训练记忆。

5 方法：同首轮候选的受控分叉

5.1 冻结起点与干预

同模型、同题、同重复首先生成一个候选。只有符合冻结资格规则的首轮失败进入反馈效应主分析。所有干预共享该失败候选及其环境，分支仅改变可见反馈或检索信息，每个分支再生成一次。

三条确认臂为无内容重试 `content_free_retry`、真实结构化诊断 `true_structured` 和反事实诊断 `counterfactual`。扩展设计增加真实原始、真实规范化、同类无关诊断、只检索和自适应路由，共八臂。无关诊断按冻结供体规则匹配，不允许自配对；无合法供体的分支按不适用保留。

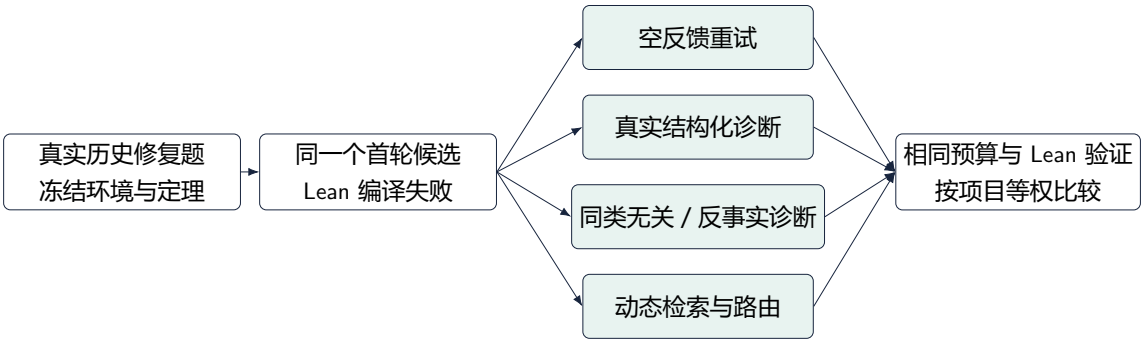


Figure 2: 同首轮失败候选分叉。图中“相同预算”指固定生成机会和输出上限，实际 token 消耗另计。真实反馈、无内容重试及负对照的比较都在模型内配对。不同模型的合格失败集合可能不同。

冻结模型配置	一方提供商	运行范围	共同约束
`deepseek-v4-pro`	DeepSeek	八臂、三重复	温度 0、输出上限 12,000 tokens
`glm-4.5`	智谱 BigModel	八臂、三重复	相同源码视图上限 24,000 字符
`MiniMax-M3`	MiniMax 中国区	三条确认臂、三重复	请求超时 600 秒

Table 2: v3 嵌套多模型设计。三条确认臂已包含在八臂中，不重复运行；各行共同约束适用于三模型。thinking/reasoning 设置、服务端标识和调用日期按原配置及轨迹披露。

5.2 三层反馈与错误状态

Compiler Feedback v1 保留 raw、normalized 和 structured 三层。原始层保留 Lean 消息并脱敏本机路径；规范化层统一位置与类别；结构化层抽取未知标识符、期望 / 实际类型、未解决目标以及 elaboration/typeclass 线索。每个结构化字段必须对应原始消息片段，便于检查转换是否丢失信息。

Error-State Graph 记录错误、信号与来源证据，Adaptive Router 当前为确定性原型。研究将检查诊断相关修改率、重复错误类别率、查询和 Top-k 变化。词法相关性是行为观察，不直接等同于模型理解或内部推理证据。

5.3 RQ2：语义敏感性与反事实跟随

真实反馈对无内容重试的比较回答 RQ1；真实反馈对同类无关 / 反事实诊断的比较回答语义对应性。两者不能互相替代：真实诊断可能优于错误诊断，却仍未优于简单重试。

当前 v3 的 counterfactual 保持原样，先核对其干预是否足够有效与可判定。后续 E3 才研究字段级定向语义变化，并引入 **Counterfactual Following Rate（CFR）**：在有效干预和可判定响应中，模型修改沿错误字段预定义方向的比例。无效干预、缺失与无法判断分别披露，另给完整分母或保守界限。编译失败或复制字符串本身不构成语义跟随。标注尽可能对模型名和最终成败盲化；未被原预注册覆盖的操作化按探索性分析标注。本次尚未报告 CFR 数值。

条件	可见信息与作用
S0	同期无内容重试基线
S1	有效真实诊断或结构化信号
S2	保留关键实体与关系，改变措辞 / 格式
S3	定向改变一个已验证的语义字段
S4	可选：删除目标信号，检查该字段贡献

Table 3: E3 后续设计。需要离线有效性门禁、开发材料上的 pilot、独立预注册与同期对照；当前 v3 不加入这些新条件。

干预前固定原始片段、变更字段、预期编辑方向及判定规则，不用参考证明构造干预。仅交换其他题目的诊断，不自动成为字段级反事实。新日期调用不能直接与可能已漂移的旧 API 对照拼成严格配对。若复用已查看的 test，需披露为已知评测集上的后续研究，不称全新跨项目验证。

5.4 RQ3：表示与 Success–Cost 权衡

raw、normalized、structured 同时比较成功率、反馈长度、输入 / 输出 tokens、延迟、编译调用和重复错误率。若 structured 成功率接近 raw、实际消耗更低，这仍可能是有意义的结果；当前不预设该关系成立。

最终绘制 Success–Cost Pareto Frontier，分别以 token 和编译调用为成本轴，比较 retry、raw、structured、retrieval 与 adaptive。只在同模型、相同合格种子覆盖下比较，报告未成功尝试的消耗；费用未知不补零。现有部分轨迹不用于提

前生成最终前沿。

E2 首先核对标识符、expected / actual type、目标、类别与 evidence span 的转换是否忠实。三种表示同时改变组织、长度和可能的信息量，因此现有比较估计的是表示方案整体效果，不能将差异全部归因于语义。未检出成功率差异不等于等效；主张保留效果时，需要另行预定可接受差异和区间。

5.5 RQ4：Error-State Graph 与 Adaptive TRACER

除最终通过外，分析 $P(e_{t+1} \mid e_t, F)$、重复错误概率、已解决信号率、新引入错误率与转向成功概率。图中的 candidate、错误类别、类型 / 目标、位置及来源证据支持可复核的状态解释；错误类别变化不自动等于证明进展。

计划中的路由状态为 $s_t = (e_t, \text{signals}, \text{history}, \text{budget})$，动作覆盖 retry、raw、normalized、structured 和 retrieval。优先使用确定性 error-aware policy，例如未知标识符可触发结构化信号与检索；这是策略空间示意，不替换当前冻结规则。

当前八臂中的 adaptive 是预先冻结的原型。若根据本次 test 结果提出新规则，应在开发 / 验证数据或独立后续协议上固定与检验，不能在同一 test 上调优后作为确认性收益。Adaptive 是研究链条的后半段，即使未改善成功–成本前沿，前面的因果与机制问题仍成立。

当前 development / validation 仅共 11 题，须先盘点状态覆盖，不能假定足以设计复杂规则。不足时增加独立开发材料或收窄策略。Oracle 的事后最优臂只作不可部署上界；静态基线在开发 / 验证材料上选择。现有一步分叉只支持 e_0 到 e_1 的转移，不把不同分支拼成同一多轮修复轨迹。

5.6 成功与信任边界

成功候选需通过目标项目中的 Lean 编译、不完整证明与候选策略检查，保存后独立复编译。imports 和声明头保持固定。Lean 通过说明该环境与可信假设下的形式有效性，不能代替对题目陈述、异常假设和示例泄漏的复核。

LeanCapsule 提供固定失败的回放工件。SP-1 至 SP-12 是独立的编译前安全策略；既有 Linux 容器报告只验证该次运行的 14 项控制。它们支持证据可信度，不作为新的反馈实验臂，也不代表通用安全沙箱。

扩展批次保存状态	数量
首轮种子记录	1,524
合格首轮失败	659
首轮成功（排除）	169
生成不完整（排除）	605
不支持的反馈类别（排除）	91
按资格计算的分支计划	5,272
已保存分支结果	4,191
其中 complete / 不适用 / error	4,163 / 27 / 1

Table 4: 2026-11-02 的本机非原子只读快照。分支记录数不是成功数，complete 也不等同于编译通过。

6 估计、预算与当前进度

6.1 主终点与分析单位

主终点是分叉后一次生成得到完整、可验证证明。设模型 m、项目 p 的合格种子集合为 S_{mp}，真实结构化反馈和无内容重试的二值结果分别为 Y_s^T, Y_s^R，预注册主效应按项目等权：

$$\widehat{\Delta}_m = \frac{1}{|P|} \sum_{p \in P} \frac{1}{|S_{mp}|} \sum_{s \in S_{mp}} (Y_s^T - Y_s^R). \quad (1)$$

实际有效项目覆盖、空集合和缺失数据按冻结门禁处理，并显式报告。各模型先独立估计，再做预注册的方向一致性汇总；不把模型间不同的合格失败集合伪装成共享种子配对。

主对比与门禁沿原注册执行。统计程序是否已冻结需逐条核对原文件及分析代码，不将新选择的区间、检验或标注回填为先验计划。只有五个 test 项目；若使用双侧精确项目符号翻转检验，最小可达 p 值为 $2/2^5 = 0.0625$。应重视项目级效应与不确定性，不以题级伪重复追求显著。

6.2 成本与选择偏差

固定调用次数、输出上限与温度不代表实际 token 预算完全相同。报告将并列给出 prompt/completion tokens、生成与编译延迟，以及可核实的账单或价格估算。GLM 和 MiniMax 未冻结价格的费用保持未知，不填 0。额外成本匹配分析若未在预注册中规定，将标记为探索性。

首轮成功、生成不完整、策略拒绝、未知结果和基础设施故障各自保留。主效应只针对合格首轮失败，不外推为所有题目的无条件效果。尤其需要按模型与项目披露资格率，避免把选择进入分析的差异解释为模型优劣。

6.3 计划依据的已保存快照

该快照中扩展批次尚无最终 summary/completion 文件；同会话根目录未发

现 MiniMax 确认批次目录。本文沿用计划对应的保存状态，不将其作为实时监控，不据此判定进程状态。当前不报告部分分支的成功率或跨臂效应。现有运行和输出目录保持原样，异常按原冻结门禁处理；659 是扩展批次合计，不能代替每模型最低 30 个合格失败的核对。

7 R1 执行顺序与预期贡献

R1 将工作分为四层：**E1** 完成当前 v3 并审计全部结果；**E2** 分析已有诊断的忠实性、语义负对照、错误状态与成本，优先不发起新证明生成；**E3** 经离线盘点、独立 pilot 与新预注册开展字段级定向语义实验；**E4** 在独立固定规则与材料上检验反馈选择。E3 / E4 不改写 E1。

内部时间目标为 11/2–11/10 收尾与核对，11/11–11/17 进行 E2，11/18–11/30 在门禁具备后开展 E3 / E4，12/1–12/23 完成写作和外部复核。日期不是官方投稿截止；未过完整性门禁即记录顺延，不为赶进度跳过审计。

E3 / E4 先盘点可用种子与字段，再固定条件数和重复。新增调用量按“新首轮生成数＋有效种子数乘条件数乘重复数＋受限基础设施余量”计算。不在未知材料与定价时编造美元预算，也不自动铺开完整大矩阵。

论文主图依次呈现因果协议、按项目与错误类型的效应、语义干预与状态变化、表示信息与 Success–Cost 权衡。Router 独立结果在完成后加入。所有未完成图保留为设计，不用预期正结果补数。

三个预期贡献为：（1）**TRACER-REAL**：真实历史修复、项目划分与来源；（2）**诊断信息结构与语义响应**：可核验的表示、误导方向及成本证据；（3）**Error-State 分析与反馈选择**：从可验证状态到独立评测的确定性策略。三供应商模型提供外部验证，LeanCapsule、SP 与工件审计提供复现支撑。Adaptive 胜出不作为研究完成门槛；正、零、负结果均按同一标准报告。

局限与研究责任

供应商别名可能漂移，训练数据不可见，模型间 tokenizer 与推理预算不同；研究需披露调用日期和可获得版本信息。五项目限制统计外推，PhysLean 占比与生成不完整排除均可能影响条件样本。AI 辅助复核不是全量纯人工数学审查。当前不声称 SOTA、普遍反馈增益或安全完备性。

本稿采用 ACL 官方双栏样式生成中文开题报告，是研究计划文档，不代表会议录用或完整英文投稿稿。公开信息与本机证据分别注明，未将进行中的 v3 输出视为完成研究。

References

Emily First, Markus N. Rabe, Talia Ringer, and Yuriy Brun. 2023. Baldur: Whole-proof generation and repair with large language models. *arXiv preprint arXiv:2303.04910*.

Jack Li and Sophia Li. 2026. Repair, retry, and the cost of hindsight: Verifier feedback in formal theorem proving. *arXiv preprint arXiv:2610.22698*.

Azim Ospanov, Farzan Farnia, and Roozbeh Yousefzadeh. 2025. Apollo: Automated llm and lean collaboration for advanced formal reasoning. *arXiv preprint arXiv:2505.05758*.

TRACER Contributors. 2026. TRACER: Typed repair agent with compiler-validated example retrieval. Software and frozen protocols. Public documentation baseline: commit 0cfd766, 2 November 2026; numerical preliminary evidence also checked against retained local release artifacts.

Huajian Xin, Z. Z. Ren, Junxiao Song, Zhihong Shao, et al. 2024. Deepseek-prover-v1.5: Harnessing proof assistant feedback for reinforcement learning and monte-carlo tree search. *arXiv preprint arXiv:2408.08152*.

Kaiyu Yang, Aidan M. Swope, Alex Gu, Rahul Chalamala, Peiyang Song, Shixing Yu, Saad Godil, Ryan Prenger, and Anima Anandkumar. 2023. Leandojo: Theorem proving with retrieval-augmented language models. *arXiv preprint arXiv:2306.15626*.